Residualer i lineære modeller

Øyvind Langsrud

December 14, 2016

Innledning

Vi tar utgangspunkt i vanlig (multippel og/eller vektet) lineær regresjon. Enkel lineær regresjon og ratemodell er spesialtilfeller av dette. Det beregnes en tilpasset verdi, $\hat{y}_i$, for hver observerte verdi y_i. Modellens variansparameter, σ^2, blir estimert og spesielt har man et standardavviksestimat

$$\widehat{\text{std}}(y_i) = s_i \tag{1}$$

slik at s_i^2 er den estimerte variansen til y_i. Når det er snakk om uvektet regresjon har vi at $s_i^2 = s^2 = \hat{\sigma}^2$.

Nedenfor trengs også begrepet

$$i\text{-te leverage} = h_{ii} \tag{2}$$

der h_{ii} er i-te element på diagonalen i den såkalte hattmatrisen som beregnes fra forklaringsvariablene (x-ene) og i tillegg vektene dersom det er snakk om vektet regresjon. Se annen litteratur for detaljer om dette.

Nedenfor har jeg valgt å bruke begrepene standardisert residual og studentisert residual slik at det samsvarer med begrepene i R (rstandard og rstudent) og mange andre programmer. Men som ellers i forbindelse med statistiske metoder er ikke begrepsbruken entydig. Alternative begreper er skrevet i parentes.

Vanlig residual

Reisualet for observasjon nummer i utrykkes ved

$$e_i = y_i - \hat{y}_i \tag{3}$$

Forventningsjustert residual

Siden residualene er avvik fra en estimert verdi og ikke avvik fra den faktiske forventningsverdien så er residualene litt får små i den forstand at e_i har litt mindre varians enn y_i. Helt konkret så er standardavviket til e_i gitt som $\sqrt{\sigma^2(1-h_{ii})}$. Skjevheten nevnt over kan dermed rettes opp ved å beregne det forventningsjusterte residualet:

$$e_i/\sqrt{1-h_{ii}} \tag{4}$$

Utenfor-modell residual

Dette residualet kan utrykkes ved

$$y_i - \hat{y}_{i(i)} = e_i/(1-h_{ii}) \tag{5}$$

der $\hat{y}_{i(i)}$ betyr at den tilpassede verdien er beregnet uten at den i-te observasjonen har vært med i modelltilpasningen. Det er svært fasinerende at alle disse verdiene kan beregnes ved en formel som benytter h_{ii}. I praksis trenger man altså ikke å foreta mange modelltilpasningen ved å holde en og en observasjon utenfor.

Det å holde en og en observasjon utenfor er basis for to beslektede metoder, jack-knife og kryssvalidering. Kryssvalidering handler om å beregne prediksjonsfeil og beregningene tar direkte utgangspunkt i utenfor-modell residualer. Man kan derfor også kalle disse residualene for kryssvaliderte residualer.

I jack-knife gjør man beregninger ved å ta utgangspunkt i ulike versjoner av et parameterestimat som oppnås når en og en observasjon holdes utenfor. Man kunne allikevel foreslå å navngi utenfor-modell residualene som jack-knife residualer, men i litteraturen brukes begrepet jack-knife residualer hovedsakelig om studentisterte residualer som er omtalt nedenfor.

Skalert residual (standardisert residual)

Et skalert residual beregnes enkelt som

$$e_i/s_i \tag{6}$$

Standardisert residual (internt studentisert residual)

Som nevnt i forbindelse med forventningsjustert residual over så er standardavviket til e_i gitt ved $\sqrt{\sigma^2(1-h_{ii})}$. Det standardiserte residualet er et residual dividert på et estimat for sitt eget standardavvik. Uttrykket for det standardiserte residualet blir dermed

$$\frac{e_i}{s_i\sqrt{1-h_{ii}}} \tag{7}$$

Det er naturlig å tenke på det standardiserte residualet som et vanlig residual som har blitt utsatt for standardisering.

Men det standardiserte residualet blir det samme uansett om man tar utgangspunkt i det vanlige residualet, det forventnigsjusterte residualet eller utenfor-modell residualet. Det er bare konstanter som skiller disse residualene, noe som vil forkortes bort ved dividering med estimert standardavvik.

Imidlertid, dersom man tar utgangspunkt i et utenfor-modell residual så vil det være naturlig å estimere standardavviket også utenfor modell. Dermed går man over til studentisert residual som beskrevet nedenfor.

Studentisert residual (eksternt studentisert residual)

Det studentiserte residualet er også et residual dividert på et estimat for sitt eget standardavvik. Denne gangen er dette standardavviket estimert ved å holde den i-te observasjonen utenfor modell og det studentiserte kan uttrykkes som

$$\frac{e_i}{s_{i(i)}\sqrt{1-h_{ii}}} \tag{8}$$

Her betyr altså $s_{i(i)}$ estimat med observasjon utenfor modell. Dette er altså nært beslektet med jack-knife som nettopp tar utgangspunkt i de ulike versjoner av et parameterestimat som oppnås når en og en observasjon holdes utenfor. Begrepet jack-knife residualer brukes derfor noen ganger om studentiserte residualer.

Det som er hovedpoenget med studentisert residual er altså at standardavviket er estimert med den aktuelle observasjonen utenfor modellen. Må må gjerne tenke på det som at selve residualtet også er et utenfor-modell residual. Men

igjen, det spiller ingen rolle om man tar utganspunkt i det vanlige residualet, det forventnigsjustert residualet eller utenfor-modell residualet. Det er bare konstanter som skiller disse residualene, noe som vil forkortes bort ved dividering med estimert standardavvik.